

Entrega Final: Ecosistema de Automatización IA Autónomo


Triage clínico de correos con memoria en Airtable, clasificación por IA y supervisión humana

Resumen del sistema

Una clínica recibe correos de pacientes que mezclan urgencias médicas con consultas administrativas. La recepción está saturada y las urgencias se pierden entre los turnos. El sistema resuelve el proceso de punta a punta: detecta el correo, lo registra, lo clasifica con IA, redacta un borrador de respuesta y lo distribuye — deteniéndose obligatoriamente ante un humano cuando la prioridad es máxima.

Categoría exigida	Tecnología	Rol en el sistema
Orquestador	Make	Dos escenarios encadenados por el estado del registro.
Base de datos	Airtable — «Ecosistema Clinica»	Memoria, registro operativo y fuente del dashboard. 4 tablas vinculadas.
Procesamiento IA	Google Gemini 3 Flash	Clasifica prioridad y redacta borrador. Prompt estructurado con salida JSON.
Canal de salida	Slack + Gmail	Slack para coordinación interna, Gmail para el paciente. Ambos respetan Thread ID.

1. Mapa de arquitectura



Recorrido del dato

Escenario 1 (automático). El trigger de Gmail toma correos no leídos con la directiva «From now on», que ignora el histórico de la casilla y evita el consumo masivo de operaciones. Un filtro de validación descarta lo que no traiga asunto y cuerpo. Con los datos completos, el flujo hace un upsert del paciente —lo crea si es nuevo, lo reconoce si ya escribió antes— y crea la solicitud

en estado Pendiente. Recién ahí interviene la IA, que devuelve un JSON con prioridad, confianza, justificación y borrador. El resultado se escribe en Airtable y un router decide el camino según el nivel de prioridad.

Punto HITL. Si la prioridad es ALTA, el flujo no contacta a nadie: publica un aviso en Slack con el borrador propuesto y deja el registro en «Esperando aprobación». Ahí se detiene, indefinidamente, hasta que una persona tilde la casilla «Aprobado» en Airtable.

Escenario 2 (distribución). Un segundo escenario vigila la vista «Listas para enviar». Su primer módulo después del trigger es un filtro que exige cuatro condiciones simultáneas. Solo si las cuatro se cumplen se envía la respuesta al paciente por Gmail, en el mismo Thread ID del correo original, se cierra el hilo en Slack y se marca el registro como Enviado.

2. Estructuras de datos documentadas

La base tiene cuatro tablas vinculadas. Ningún dato queda aislado: los umbrales de SLA y la regla de aprobación viven en su propia tabla de catálogo en vez de estar escritos dentro del flujo, de modo que cambiar una regla de negocio no obliga a tocar la automatización.

2.1 Relaciones entre tablas

Pacientes 1

< N Solicitudes N >

1 Prioridades

Log_Errores

Un paciente acumula muchas solicitudes.

Cada solicitud apunta a un nivel del catalogo de prioridades.

Una solicitud puede acumular varios errores.

2.2 Tabla Solicitudes — operativa

Campo	Tipo	Escribe	Función
Message_ID	Single line text	Make	ID de Gmail. Clave anti-duplicado.
Thread_ID	Single line text	Make	Mantiene la conversación agrupada en Gmail y Slack.
Asunto / Cuerpo / Remitente	Text / Long text / Email	Make	Contenido del correo entrante.
Paciente	Link → Pacientes	Make	Relación por email. Da memoria al sistema.
Estado	Single select (7 valores)	Make + Humano	Pendiente · Procesado por IA · Esperando aprobación · Aprobado por Humano · Enviado · Rechazado · Error
Prioridad_IA	Link → Prioridades	Make	Resultado de la clasificación.
Confianza_IA	Number (2 dec.)	Make	Se compara como número, nunca como texto.
Borrador_Respuesta	Long text	Make	Texto propuesto al paciente.
Aprobado	Checkbox	Solo Humano	El semáforo HITL. Fuera de los permisos de escritura de Make.
Tiempo_respuesta_min	Formula	Airtable	DATETIME_DIFF entre aprobación e ingreso.

Campo	Tipo	Escribe	Función
Dentro_SLA	Formula	Airtable	Compara contra SLA_minutos del catálogo.
Errores	Link → Log_Errores	Make	Trazabilidad de fallos por solicitud.

2.3 Tablas de soporte

Tabla	Campos	Para qué existe
Pacientes	Email (PK) · Nombre · Total_solicitudes (count) · Ultima_interaccion · Notas_internas	Memoria del sistema. Permite reconocer a quien ya escribió y contar su historial sin duplicar registros.
Prioridades	Nivel · SLA_minutos · Requiere_aprobacion · Canal_salida · Descripcion	Catálogo maestro. Evita hardcodear los umbrales dentro del flujo: la regla de negocio es un dato, no código.
Log_Errores	Modulo · Tipo_error · Mensaje · Reintentos · Resuelto · Fecha	Registro de resiliencia. Es la fuente del KPI de tasa de errores del dashboard.

2.4 Esquema JSON de transferencia — salida del nodo de IA

El prompt obliga al modelo a devolver exclusivamente este objeto, sin texto alrededor. Un módulo Parse JSON lo convierte en variables mapeables; si el modelo devolviera algo que no es JSON válido, el error handler de ese módulo lo registra en Log_Errores.

```
{
  "prioridad":  "ALTA",
  "confianza":  0.94,
  "justificacion":"El remitente refiere dolor agudo y sangrado post operatorio.",
  "borrador":   "Recibimos su mensaje y lo derivamos al equipo medico..."
}
```

2.5 Esquema JSON de transferencia — escritura en Airtable

Los tipos importan. Confianza_IA viaja como número y Aprobado como booleano: si alguno viajara entre comillas, las comparaciones del router y del filtro HITL fallarían silenciosamente en vez de arrojar error.

```
{
  "Message_ID":    "199f2a1c8be292",    // string — clave anti-duplicado
  "Thread_ID":    "199f2a1c8be291",    // string — mantiene el hilo
  "Asunto":        "URGENCIA - dolor...", // string
  "Cuerpo":        "Tengo dolor agudo...", // string largo
  "Remitente":     "paciente@correo.com", // email
  "Paciente":      ["recXXXXXXXX"],      // array de record IDs
  "Estado":        "Pendiente",          // enum de 7 valores
  "Prioridad_IA":  ["recYYYYYYYY"],      // array de record IDs
  "Confianza_IA":  0.94,                  // number — NO string
  "Justificación_IA": "...",              // string
  "Borrador_Respuesta": "...",            // string largo
  "Aprobado":      false,                 // boolean — NO "false"
  "Canal_enviado": null                    // enum o null
}
```

3. Optimización de costos

El criterio de selección no es «usar el modelo más barato» ni «usar el más capaz», sino asignar a cada tarea el modelo más chico que la resuelve con calidad suficiente, y aprovechar los descuentos estructurales cuando la tarea tolera latencia.

3.1 Matriz de decisión por tarea

Tarea	Modelo elegido	Modo	Por qué	Descartados
Clasificar prioridad del correo (400/mes)	Gemini 3 Flash / GPT-5-nano	Síncrono	Decisión binaria sobre texto corto. No requiere razonamiento profundo. La latencia importa: hay urgencias en juego.	Opus 5 y Sonnet 5: sobredimensionados, cuestan entre 40 y 70 veces más para la misma decisión.
Redactar borrador de respuesta	Gemini 3 Flash	Síncrono	Texto breve y estructurado, con plantilla y restricciones claras. Va a revisión humana igual.	GPT-5-nano: redacción más pobre en español rioplatense.
Auditoría mensual de 500 historiales	Claude Sonnet 5	Batch + Prompt Caching	Lectura densa de documentos largos, sin urgencia. Tolerar 24 h de latencia, lo que habilita el 50% de descuento.	Modelos nano: pierden precisión en documentos clínicos extensos.
Extracción de datos estructurados	GPT-5-nano	Batch	Tarea mecánica de alto volumen sin ambigüedad.	Cualquier modelo grande: gasto injustificado.

3.2 Comparativa de costo — clasificación de 400 correos/mes

Supuestos: 1.200 tokens de entrada y 350 de salida por correo. Tarifas oficiales verificadas en agosto de 2026.

Modelo	Entrada	Salida	Total mensual	Ahorro vs. Opus 5
GPT-5-nano	USD 0,024	USD 0,056	USD 0,080	98,6 %
GPT-4o-mini	USD 0,072	USD 0,084	USD 0,156	97,4 %
GPT-5-mini	USD 0,120	USD 0,280	USD 0,400	93,2 %
Claude Haiku 4.5	USD 0,480	USD 0,700	USD 1,180	80,0 %
Claude Sonnet 5	USD 1,440	USD 2,100	USD 3,540	40,0 %
Claude Opus 5	USD 2,400	USD 3,500	USD 5,900	—

3.3 Tarea masiva: efecto de Batch API y Prompt Caching

La auditoría mensual de 500 historiales usa un prefijo estático de 12.000 tokens —protocolo clínico y rúbrica— idéntico en las 500 llamadas. Ese bloque se escribe en caché una vez y se lee 499 veces a un décimo del precio.

Tarifas efectivas Claude Sonnet 5 en modo Batch (50% de descuento):
entrada 3,00 x 0,5 = USD 1,50 / MTok
salida 15,00 x 0,5 = USD 7,50 / MTok
escritura de cache 1 h . 1,50 x 2,0 = USD 3,00 / MTok
lectura de cache 1,50 x 0,1 = USD 0,15 / MTok

Escritura del prefijo (1 vez): 12.000 tok USD 0,036
Lecturas del prefijo (499 veces): 5.988.000 tok USD 0,898
Contenido dinamico: 4.000.000 tok USD 6,000
Salida: 600.000 tok USD 4,500

TOTAL DEL LOTE USD 11,434
(sin optimizar seria USD 39,00 — ahorro del 70,7%)

3.4 Impacto presupuestario consolidado

Escenario	Costo mensual	Costo anual	Diferencia
Ingenuo: todo con Opus 5 en modo síncrono	USD 70,90	USD 850,80	—
Optimizado: nano para triage + Sonnet Batch/Cache para auditoría	USD 11,51	USD 138,17	USD 712,63 de ahorro anual (83,8 %)

Los porcentajes no se suman de forma lineal: la Batch API descuenta sobre el total facturado mientras que el caché reduce la cantidad de tokens facturados a tarifa plena. Se componen de manera multiplicativa.

Control adicional en el flujo: el nodo de IA tiene max_tokens fijado en 800. La respuesta esperada ronda los 350; el techo evita que una respuesta descontrolada infle la factura.

4. Seguridad y resiliencia

4.1 Minimización de datos

El sistema maneja correspondencia médica, que es información sensible. El principio aplicado es que cada componente reciba lo mínimo indispensable para su función.

- Al nodo de IA viajan únicamente asunto, cuerpo y remitente del correo. El historial clínico del paciente, sus notas internas y el conteo de interacciones previas nunca salen de Airtable.
- El aviso a Slack incluye asunto, prioridad y borrador, pero no el cuerpo completo del correo: el canal interno no necesita el relato médico entero para decidir si aprobar.
- Las credenciales viven en las conexiones de Make, nunca en el cuerpo de los módulos. En el blueprint exportado que acompaña esta entrega, los identificadores de conexión fueron reemplazados por marcadores del tipo __GMAIL_CONNECTION__.
- El campo Aprobado está fuera de los permisos de escritura del token de Airtable usado por Make. Aunque un módulo intentara marcarlo, la API lo rechazaría.
- El enlace público de la base se comparte en modo solo lectura; el dashboard expone métricas agregadas, no contenido de correos.

4.2 Rutas de error

Punto de fallo	Directiva	Comportamiento	Registro
Correo sin asunto o sin cuerpo (camino infeliz)	Filtro de validación	El bundle no avanza. No se llama a la IA ni se gasta un token.	Log_Errores · Tipo = Dato faltante
API de IA caída o con timeout	Retry	3 reintentos espaciados 15 minutos. Si persiste, la	Log_Errores · Tipo = API caída · Reintentos = 3

Punto de fallo	Directiva	Comportamiento	Registro
		solicitud queda en Estado = Error y no se pierde.	
La IA devuelve algo que no es JSON válido	Error handler del Parse JSON	Se corta esa solicitud sin arrastrar al resto del lote.	Log_Errores · Tipo = Respuesta inválida, con el texto crudo recibido
Gmail o Slack rechazan el envío	Resume	El lote continúa con las demás solicitudes en vez de abortar entero.	Log_Errores · Tipo = API caída, vinculado a la solicitud
Airtable no responde	Retry + Break	Reintenta; si falla, la ejecución va a la cola de incompletas para reproceso manual.	Cola de ejecuciones incompletas de Make

La distinción entre Retry, Resume y Break es deliberada. Retry se usa donde el fallo suele ser transitorio (una API que no responde). Resume se usa donde conviene sacrificar un registro antes que frenar el lote completo. Break se reserva para lo que exige intervención humana y no debe perderse.

4.3 Punto de validación humana (HITL)

La acción crítica del sistema es contactar a un paciente con una urgencia médica. Ahí el flujo se detiene.

Elemento	Implementación
Dónde se detiene	Después de clasificar y redactar, antes de cualquier contacto con el paciente, cuando Prioridad_IA = ALTA.
Cómo avisa	Mensaje a Slack en #urgencias-clinica con asunto, nivel de confianza, justificación de la IA, borrador propuesto y enlace directo al registro.
Qué revisa la persona	Que la clasificación sea correcta, que el borrador no prometa diagnósticos ni plazos médicos, y que no haya datos inventados.
Cómo se aprueba	Tildando la casilla «Aprobado» en Airtable. Es el único campo que la automatización no puede escribir.
Qué pasa si no aprueba	El registro queda en Rechazado con el motivo. El paciente no es contactado por el sistema y el caso pasa a gestión manual.
La barrera técnica	El escenario 2 tiene un filtro con cuatro condiciones: Aprobado = true (booleano), Estado = «Aprobado por Humano», Borrador existe y Canal_enviado vacío. Si alguna falla, el módulo de Gmail no llega a ejecutarse.

La diferencia con una instrucción del tipo «acordate de revisar antes de enviar» es que acá no hay nada que recordar. El bundle no atraviesa el filtro y el historial de Make lo registra como «The bundle did not pass through the filter». La disciplina la impone la arquitectura.

4.4 Check de seguridad

Verificación	Estado	Cómo se resuelve
¿Hay filtro contra bucles infinitos?	Sí	El trigger usa «From now on» y la vista de disparo exige Estado = Pendiente, condición que deja de cumplirse apenas la IA escribe el

Verificación	Estado	Cómo se resuelve
		resultado. En el escenario 2, Canal_enviado vacío impide el doble envío.
¿Se comparan tipos de datos correctos?	Sí	Aprobado se compara como booleano (boolean:equal contra true), Confianza_IA y SLA_minutos como números, Estado y Prioridad como texto. Nunca texto contra número.
¿El prompt es dinámico y usa variables del sistema?	Sí	El prompt inyecta {{2.subject}}, {{2.fromEmail}} y {{2.fullTextBody}} del trigger. No hay ningún dato del caso escrito de forma fija.
¿Hay datos hardcoded en la lógica?	No	Los umbrales de SLA y la regla de aprobación se leen de la tabla Prioridades. Cambiar una regla de negocio no requiere editar el flujo.
¿Los nodos están nombrados?	Sí	Cada módulo lleva nombre descriptivo y numerado, visible en el blueprint bajo metadata.designer.name.

5. Dashboard de control

El panel se construyó como una Interface de Airtable sobre las mismas tablas que escribe el orquestador, de modo que no requiere sincronización: lo que el flujo escribe, el dashboard lo refleja.

Indicador	Cálculo	Qué permite detectar
Solicitudes totales del período	Conteo de registros en Solicitudes	Volumen de demanda y estacionalidad.
Distribución por estado	Agrupación por Estado	Cuellos de botella. Un montón de registros en «Esperando aprobación» indica que el equipo no está revisando a tiempo.
Volumen por prioridad	Agrupación por Prioridad_IA	Proporción de urgencias reales. Si sube mucho, puede indicar que el prompt está sobreclasificando.
Tasa de errores	Registros en Log_Errores sobre total de solicitudes	Salud técnica del sistema. Es el KPI de resiliencia.
Tiempo medio de aprobación	Promedio de Tiempo_respuesta_min	Qué tan rápido responde el humano en el punto HITL.
Cumplimiento de SLA	Porcentaje con Dentro_SLA = SI	Si las urgencias se atienden dentro de los 15 minutos comprometidos.
Errores abiertos	Log_Errores con Resuelto sin tildar	Cola de incidentes pendientes de atención técnica.

Enlace público al dashboard: *[completar con el link de la Shared View de Airtable]*

Enlace a la base en modo lectura: *[completar con el link público de solo lectura]*

6. Estado de implementación y pruebas

El Escenario 1 (Ecosistema Clinica — Escenario 1) está completamente armado, conectado y guardado en Make: los 12 módulos del blueprint más sus error handlers quedaron resueltos a sus tipos reales, con conexión activa en Gmail, Airtable y Slack. La conexión de Airtable se resolvió generando un Personal Access Token desde una cuenta colaboradora de la base, porque el correo de verificación de Airtable nunca llegó a la casilla principal.

Verificación previa a la corrida	Estado
Los 12 módulos resueltos a su tipo real (sin «Module Not Found»)	Hecho
Conexiones activas: Gmail, Airtable, Slack	Hecho
Escenario guardado sin errores de referencia entre módulos	Hecho
Dos correos de prueba enviados a la casilla monitoreada (uno ALTA, uno NORMAL)	Hecho
Ejecución «Run once» de punta a punta	⚠ Pendiente
Test de estrés de 5 corridas, incluyendo camino infeliz	⚠ Pendiente

La prueba en vivo quedó pendiente por un límite operativo, no de diseño: al ejecutar «Run once», Make devolvió «Scenario is paused (because of exceeded limits)». La cuenta agotó el 100 % de los créditos del plan Free (1.000/1.000) y el reseteo mensual cae después de la fecha de entrega. El escenario no tiene ningún bloqueo de configuración pendiente: en cuanto se renueve el crédito (o se haga upgrade de plan) va a procesar sin cambios adicionales los dos correos de prueba que ya están en cola, y ahí corresponde correr el test de estrés de 5 corridas.

Anexo — Prompt del nodo de IA

Prompt estructurado con rol, restricción de formato de salida, regla anti-alucinación y variables dinámicas del trigger.

```
INSTRUCCION Estricta: actúas como clasificador de triage para una clínica
médica. NO eres un asistente conversacional. Devuelve ÚNICAMENTE un objeto
JSON válido, sin texto antes ni después, con exactamente estas cuatro claves:
prioridad, confianza, justificación, borrador.

prioridad: la cadena ALTA o NORMAL. ALTA si el mensaje describe urgencia
médica, dolor agudo, sangrado, cirugía inminente o reclamo
grave. NORMAL en cualquier otro caso.
confianza: número entre 0 y 1 con dos decimales.
justificación: una oración citando la parte del correo que motivó la
clasificación.
borrador: respuesta sugerida al paciente, máximo 80 palabras, tono
profesional y empático, sin prometer diagnósticos ni plazos.

REGLA ANTI-ALUCINACIÓN: no inventes datos clínicos, turnos ni nombres de
profesionales que no figuren en el correo.

Correo a clasificar:
Asunto: {{2.subject}}
Remitente: {{2.fromEmail}}
Contenido: {{2.fullTextBody}}
```

Fuentes de precios: documentación oficial de Anthropic (platform.claude.com/docs/en/about-claude/pricing) y de OpenAI (developers.openai.com/api/docs/pricing), consultadas en agosto de 2026.